

http://algs4.cs.princeton.edu

5.4 REGULAR EXPRESSIONS

- *regular expressions*
- *REs and NFAs*
- *NFA simulation*
- *NFA construction*
- *applications*



5.4 Regular Expressions

- *regular expressions*
- *REs and NFAs*
- *NFA simulation*
- *NFA construction*
- *applications*

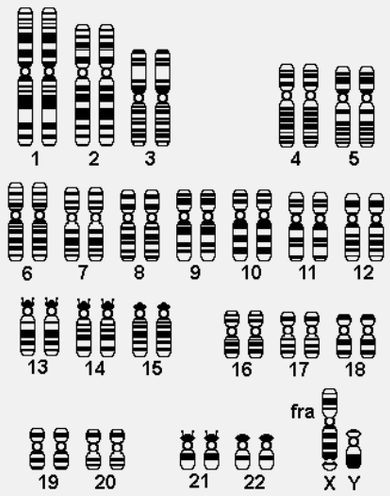
Pattern matching

Substring search. Gjej një në tekst.

Pattern matching. Gjej një nga bashkësitë specifike të strings në tekst.

P.Sh. [genomics]

- Sindromi fragjil X është shkaktari kryesorë i retardimit.
- Gjenomi i njeriut është një a string.
- Përmbanë përsëritje të trefishta të CGG ose AGG, që fillojnë me GCG dhe përfundojnë me CTG.
- Numri i përsëritjeve varion dhe është në korelacion me sindromin.



pattern GCG(CGG|AGG)*CTG

tekst GCGGCGTGTGTGCGAGAGAGTGGGTTTAAAGCTGGCGCGGAGGCGGCTGGCGCGGAGGCTG

Syntax highlighting

```
/*************************************************************************
 *  Compilation:  javac NFA.java
 *  Execution:    java NFA regexp text
 *  Dependencies: Stack.java Bag.java Digraph.java  DirectedDFS.java
 *
 *  % java NFA "(A*B|AC)D" AAAABD
 *  true
 *
 *  % java NFA "(A*B|AC)D" AAAAC
 *  false
 *
 *************************************************************************/

public class NFA
{
    private Digraph G;          // digraph of epsilon transitions
    private String regexp;      // regular expression
    private int M;              // number of characters in regular expression

    // Create the NFA for the given RE
    public NFA(String regexp)
    {                   regexp;
        this.regexp =
        M = regexp.length();
        Stack<Integer> ops = new Stack<Integer>();
        G = new Digraph(M+1);
        ...
```

input	output
Ada	HTML
Asm	XHTML
Applescript	LATEX
Awk	MediaWiki
Bat	ODF
Bib	TEXINFO
Bison	ANSI
C/C++	DocBook
C#	
Cobol	
Caml	
Changelog	
Css	
D	
Erlang	
Flex	
Fortran	
GLSL	
Haskell	
Html	
Java	
Javalog	
Javascript	
Latex	
Lisp	
Lua	
⋮	

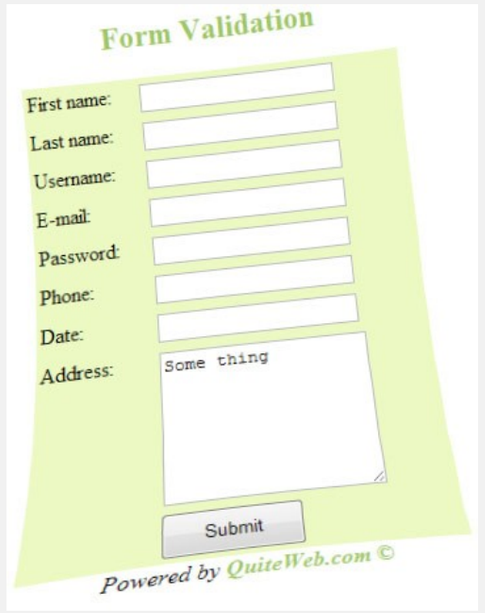
GNU source-highlight 3.1.4

Pattern matching: aplikimet

Test nëse një string match ndonjë pattern.

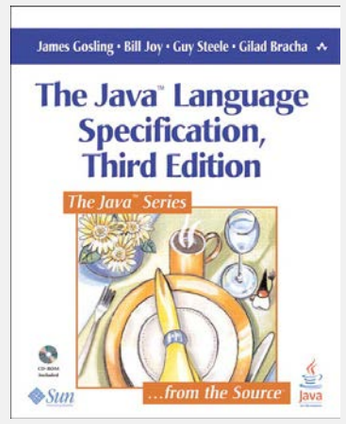


- Skanimi për virus signature (identifikues algoritmik i virusit).
- Procesimi i gjuhës natyrale (NLP).
- Specifikimi i një gjuhe programuese.
- Qasja në informata në librari dixhitale.
- Kërkimi i gjenomit duke përdorur PROSITE patterns.
- Filtrimi i tekstit (spam, malware).
- Validimi i data-entry fushave (datat, e-mail, URL, credit card).



...

Parsimi i text files.



- Kompajllimi i një Java programi.
- Crawl dhe index Web-in (deep web).
- Read të dhënat e ruajtura në një ad hoc input file format.
- Krijimi i Java dokumentacionit nga Javadoc komentet.

Regular expressions

Një regular expression është një symbol që specifikon një bashkësi të string-ave.

operation	order	example RE	matches	does not match
concatenation	3	AABAAB	AABAAB	*every other string*
or	4	AA | BAAB	AA BAAB	*every other string*
closure	2	AB*A	AA ABBBBBBBBA	AB ABABA
parentheses	1	A(A|B)AAB	AAAAB ABAAB	*every other string*
		(AB)*A	A ABABABABABA	AA ABBA

Regular expression shortcuts

Operacione shtesë shtohen shpeshë për të bërë punën më të lehtë.

operation	example RE	matches	does not match
wildcard	`.U.U.U.`	CUMULUS JUGULUM	SUCCUBUS TUMULTUOUS
character class	`[A-Za-z][a-z]*`	word Capitalized	camelCase 4illegal
at least 1	`A(BC)+DE`	ABCDE ABCBCDE	ADE BCDE
exactly k	`[0-9]{5}-[0-9]{4}`	08540-1321 19072-5541	111111111 166-54-111

Ex. `[A-E]+` is shorthand for `(A|B|C|D|E)(A|B|C|D|E)*`

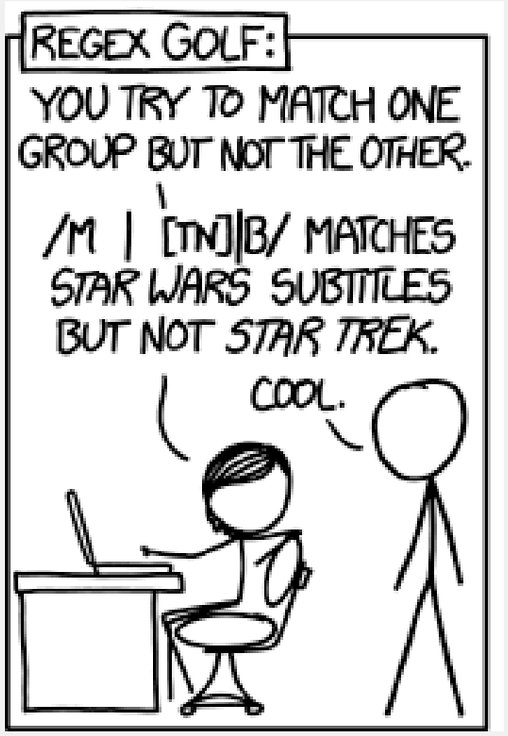
Regular expression examples

RE simbolizimi është shumë i shprehur.

regular expression	matches	does not match
`.*SPB.*` (*substring search*)	RASPBERRY CRISPBREAD	SUBSPACE SUBSPECIES
`[0-9]{3}-[0-9]{2}-[0-9]{4}` (*U. S. Social Security numbers*)	166-11-4433 166-45-1111	11-55555555 8675309
`[a-z]+@([a-z]+\.)+(edu|com)` (*simplified email addresses*)	wayne@princeton.edu rs@princeton.edu	spam@nowhere
`[$_A-Za-z][$_A-Za-z0-9]*` (*Java identifiers*)	ident3 PatternMatcher	3a ident#3

REs luajnë rol të rëndësishëm në teorinë e kompjutimit (theory of computation).

Regular expression golf



http://xkcd.com/1313

yes	no
obama	romney
bush	mccain
clinton	kerry
reagan	gore
…	…
washington	clinton

Ex. Match kryetarët e zgjedhur por jo kundërkandidatët (perveç nëse kanë fituar më vonë).

RE. `bu|[rn]t|[coy]e|[mtg]a|j|iso|n[hl]|[ae]d|lev|sh|[lnd]i|[po]o|ls`

madison harrison

Kontrollimi illegal për kandidatë pune

```
“ [First name]! and pre/2 [last name] w/7
   bush or gore or republican! or democrat! or charg!
   or accus! or criticiz! or blam! or defend! or iran contra
   or clinton or spotted owl or florida recount or sex!
   or controvers! or fraud! or investigat! or bankrupt!
   or layoff! or downsiz! or PNTR or NAFTA or outsourc!
   or indict! or enron or kerry or iraq or wmd! or arrest!
or intox! or fired or racis! or intox! or slur!
or controvers! or abortion! or gay! or homosexual!
or gun! or firearm! ”
```

— LexisNexis search string used by Monica Goodling to illegally screen candidates for DOJ positions



LexisNexis™

http://www.justice.gov/oig/special/s0807/final.pdf

Përdoruesi mesatar i web-it mund të përdorë REtë?

Google. Përkrahë * për fjalë *wildcard* dhe | për union.



Regular expressions zgjidhin problemin



http://xkcd.com/208

Programeri mesatar mund të përdorë REtë?

Perl RE për RFC822 valid email adresa

```
  (?:(?:\r\n)?[ \t])*(?:(?:(?:[^()<>@,;:\\".\[\] \000-\031]+(?:(?:(?:\r\n)?[ \t])+|\Z|(?=[\["()<>@,;:\\".\[\]]))|"(?:[^\"\r\\]|\\.|(?:(?:\r\n)?[ \t]))*"(?:(?:
\r\n)?[ \t])*)(?:\.(?:(?:\r\n)?[ \t])*(?:[^()<>@,;:\\".\[\] \000-\031]+(?:(?:(?:\r\n)?[ \t])+|\Z|(?=[\["()<>@,;:\\".\[\]]))|"(?:[^\"\r\\]|\\.|(?:(?:\r\n)?[
  \t]))*"(?:(?:\r\n)?[ \t])*))*@(?:(?:\r\n)?[ \t])*(?:[^()<>@,;:\\".\[\] \000-\031]+(?:(?:(?:\r\n)?[ \t])+|\Z|(?=[\["()<>@,;:\\".\[\]]))|\[([^\[\]\r\\]|\\.)*\
 ](?:(?:\r\n)?[ \t])*)(?:\.(?:(?:\r\n)?[ \t])*(?:[^()<>@,;:\\".\[\] \000-\031]+(?:(?:(?:\r\n)?[ \t])+|\Z|(?=[\["()<>@,;:\\".\[\]]))|\[([^\[\]\r\\]|\\.)*\](?:
  (?:\r\n)?[ \t])*))*|(?:[^()<>@,;:\\".\[\] \000-\031]+(?:(?:(?:\r\n)?[ \t])+|\Z|(?=[\["()<>@,;:\\".\[\]]))|"(?:[^\"\r\\]|\\.|(?:(?:\r\n)?[ \t]))*"(?:(?:\r\n)
  ?[ \t])*)*\<(?:(?:\r\n)?[ \t])*(?:@(?:[^()<>@,;:\\".\[\] \000-\031]+(?:(?:(?:\r\n)?[ \t])+|\Z|(?=[\["()<>@,;:\\".\[\]]))|\[([^\[\]\r\\]|\\.)*\](?:(?:\r\n)?[
   \t])*)(?:\.(?:(?:\r\n)?[ \t])*(?:[^()<>@,;:\\".\[\] \000-\031]+(?:(?:(?:\r\n)?[ \t])+|\Z|(?=[\["()<>@,;:\\".\[\]]))|\[([^\[\]\r\\]|\\.)*\](?:(?:\r\n)?[ \t]
  )*))*(?:,@(?:(?:\r\n)?[ \t])*(?:[^()<>@,;:\\".\[\] \000-\031]+(?:(?:(?:\r\n)?[ \t])+|\Z|(?=[\["()<>@,;:\\".\[\]]))|\[([^\[\]\r\\]|\\.)*\](?:(?:\r\n)?[ \t])*
  )(?:\.(?:(?:\r\n)?[ \t])*(?:[^()<>@,;:\\".\[\] \000-\031]+(?:(?:(?:\r\n)?[ \t])+|\Z|(?=[\["()<>@,;:\\".\[\]]))|\[([^\[\]\r\\]|\\.)*\](?:(?:\r\n)?[ \t])*))*)
  *:(?:(?:\r\n)?[ \t])*)?(?:[^()<>@,;:\\".\[\] \000-\031]+(?:(?:(?:\r\n)?[ \t])+|\Z|(?=[\["()<>@,;:\\".\[\]]))|"(?:[^\"\r\\]|\\.|(?:(?:\r\n)?[ \t]))*"(?:(?:\r
  \n)?[ \t])*)(?:\.(?:(?:\r\n)?[ \t])*(?:[^()<>@,;:\\".\[\] \000-\031]+(?:(?:(?:\r\n)?[ \t])+|\Z|(?=[\["()<>@,;:\\".\[\]]))|"(?:[^\"\r\\]|\\.|(?:(?:\r\n)?[ \t
  ]))*"(?:(?:\r\n)?[ \t])*))*@(?:(?:\r\n)?[ \t])*(?:[^()<>@,;:\\".\[\] \000-\031]+(?:(?:(?:\r\n)?[ \t])+|\Z|(?=[\["()<>@,;:\\".\[\]]))|\[([^\[\]\r\\]|\\.)*\](
  ?:(?:\r\n)?[ \t])*)(?:\.(?:(?:\r\n)?[ \t])*(?:[^()<>@,;:\\".\[\] \000-\031]+(?:(?:(?:\r\n)?[ \t])+|\Z|(?=[\["()<>@,;:\\".\[\]]))|\[([^\[\]\r\\]|\\.)*\](?:(?
  :\r\n)?[ \t])*))*\>(?:(?:\r\n)?[ \t])*)|(?:[^()<>@,;:\\".\[\] \000-\031]+(?:(?:(?:\r\n)?[ \t])+|\Z|(?=[\["()<>@,;:\\".\[\]]))|"(?:[^\"\r\\]|\\.|(?:(?:\r\n)?
  [ \t]))*"(?:(?:\r\n)?[ \t])*)*:(?:(?:\r\n)?[ \t])*(?:(?:(?:[^()<>@,;:\\".\[\] \000-\031]+(?:(?:(?:\r\n)?[ \t])+|\Z|(?=[\["()<>@,;:\\".\[\]]))|"(?:[^\"\r\\]|
  \\.|(?:(?:\r\n)?[ \t]))*"(?:(?:\r\n)?[ \t])*)(?:\.(?:(?:\r\n)?[ \t])*(?:[^()<>@,;:\\".\[\] \000-\031]+(?:(?:(?:\r\n)?[ \t])+|\Z|(?=[\["()<>@,;:\\".\[\]]))|"
  (?:[^\"\r\\]|\\.|(?:(?:\r\n)?[ \t]))*"(?:(?:\r\n)?[ \t])*))*@(?:(?:\r\n)?[ \t])*(?:[^()<>@,;:\\".\[\] \000-\031]+(?:(?:(?:\r\n)?[ \t])+|\Z|(?=[\["()<>@,;:\\".
  \[\]]))|\[([^\[\]\r\\]|\\.)*\](?:(?:\r\n)?[ \t])*)(?:\.(?:(?:\r\n)?[ \t])*(?:[^()<>@,;:\\".\[\] \000-\031]+(?:(?:(?:\r\n)?[ \t])+|\Z|(?=[\["()<>@,;:\\".\[\]
  ]))|\[([^\[\]\r\\]|\\.)*\](?:(?:\r\n)?[ \t])*))*\>(?:(?:\r\n)?[ \t])*)(?:,\s*(?:(?:[^()<>@,;:\\".\[\] \000-\031]+(?:(?:(?:\r\n)?[ \t])+|\Z|(?=[\["()<>@,;:\\
  ".\[\]]))|"(?:[^\"\r\\]|\\.|(?:(?:\r\n)?[ \t]))*"(?:(?:\r\n)?[ \t])*)(?:\.(?:(?:\r\n)?[ \t])*(?:[^()<>@,;:\\".\[\] \000-\031]+(?:(?:(?:\r\n)?[ \t])+|\Z|(?=[
  \["()<>@,;:\\".\[\]]))|"(?:[^\"\r\\]|\\.|(?:(?:\r\n)?[ \t]))*"(?:(?:\r\n)?[ \t])*))*@(?:(?:\r\n)?[ \t])*(?:[^()<>@,;:\\".\[\] \000-\031]+(?:(?:(?:\r\n)?[ \t
  ])+|\Z|(?=[\["()<>@,;:\\".\[\]]))|\[([^\[\]\r\\]|\\.)*\](?:(?:\r\n)?[ \t])*)(?:\.(?:(?:\r\n)?[ \t])*(?:[^()<>@,;:\\".\[\] \000-\031]+(?:(?:(?:\r\n)?[ \t])+|
  \Z|(?=[\["()<>@,;:\\".\[\]]))|\[([^\[\]\r\\]|\\.)*\](?:(?:\r\n)?[ \t])*))*|(?:[^()<>@,;:\\".\[\] \000-\031]+(?:(?:(?:\r\n)?[ \t])+|\Z|(?=[\["()<>@,;:\\".\[
  ]]))|"(?:[^\"\r\\]|\\.|(?:(?:\r\n)?[ \t]))*"(?:(?:\r\n)?[ \t])*)*\<(?:(?:\r\n)?[ \t])*(?:@(?:[^()<>@,;:\\".\[\] \000-\031]+(?:(?:(?:\r\n)?[ \t])+|\Z|(?=[\[
  "()<>@,;:\\".\[\]]))|\[([^\[\]\r\\]|\\.)*\](?:(?:\r\n)?[ \t])*)(?:\.(?:(?:\r\n)?[ \t])*(?:[^()<>@,;:\\".\[\] \000-\031]+(?:(?:(?:\r\n)?[ \t])+|\Z|(?=[\["()<>@,;:\\
  ".\[\]]))|\[([^\[\]\r\\]|\\.)*\](?:(?:\r\n)?[ \t])*))*:(?:(?:\r\n)?[ \t])*)?(?:[^()<>@,;:\\".\[\] \000-\031]+(?:(?:(?:\r\n)?[ \t])+|\Z|(?=[\["()<>@,;:\\".
  \[\]]))|"(?:[^\"\r\\]|\\.|(?:(?:\r\n)?[ \t]))*"(?:(?:\r\n)?[ \t])*)(?:\.(?:(?:\r\n)?[ \t])*(?:[^()<>@,;:\\".\[\] \000-\031]+(?:(?:(?:\r\n)?[ \t])+|\Z|(?=[\[
  "()<>@,;:\\".\[\]]))|\[([^\[\]\r\\]|\\.)*\](?:(?:\r\n)?[ \t])*))*@(?:(?:\r\n)?[ \t])*(?:[^()<>@,;:\\".\[\] \000-\031]+(?:(?:(?:\r\n)?[ \t])
  +|\Z|(?=[\["()<>@,;:\\".\[\]]))|\[([^\[\]\r\\]|\\.)*\](?:(?:\r\n)?[ \t])*)(?:\.(?:(?:\r\n)?[ \t])*(?:[^()<>@,;:\\".\[\] \000-\031]+(?:(?:(?:\r\n)?[ \t])+|\Z
|(?=[\["()<>@,;:\\".\[\]]))|\[([^\[\]\r\\]|\\.)*\](?:(?:\r\n)?[ \t])*))*\>(?:(?:\r\n)?[ \t])*))*)?;\s*)
```

http://www.ex-parrot.com/~pdw/Mail-RFC822-Address.html

Regular expression - mangësitë

Shkrimi i RE gjason me shkrimin e një programi

- Duhet të kuptohet modeli programues.
- Ndodhë që më lehtë shkruhet sesa që lexohet.
- Ndodhë të jetë vështirë për të debug.



> *“ Some people, when confronted with a problem, think 'I know I'll use regular expressions.' Now they have two problems. ”*
>
> *— Jamie Zawinski (flame war on alt.religion.emacs)*

Përfundim. REtë janë jashtëzakonisht të fuqishme dhe spekter të gjerë të të shprehurit, mirëpo pĽrdorimi I tyre në aplikacione mund të jetë mjaft kompleks dhe i prirur për gabime.



http://algs4.cs.princeton.edu

5.4 Regular Expressions

- *regular expressions*
- *REs and NFAs*
- *NFA simulation*
- *NFA construction*
- *applications*

Dualiteti në mes të REve dhe DFAve

RE. Mënyrë për të përshkruar një bashkësi të string-ëve

DFA. Maqinë për të gjetur nëse një string i dhënë gjindet në një bashkësi apo jo.

Teorema e Kleene-it.

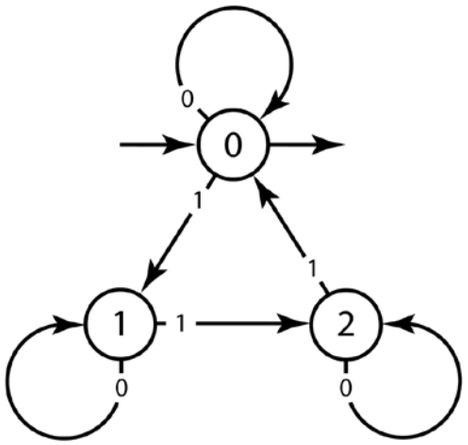
- Për çdo DFA, ekziston një RE që përshkruan të njejtën bashkësi të string-ave.
- Për çdo RE, ekziston një DFA që njeh të njejtën bashkësi të string-ave.

RE

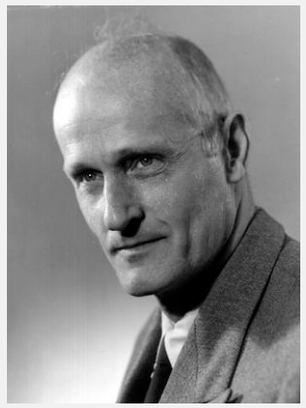
```
0* | (0*10*10*10*)*
```

numri i 1ve është shumëfish i 3

DFA



numri i 1ve është shumëfish i 3

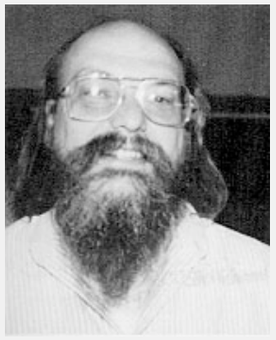


Stephen Kleene
Princeton Ph.D. 1934

Pattern matching implementimi: plani bazik (tentimi i parë)

Ngjajshëm me KMP.

- Pa backup në input stream për tekst.
- Koha lineare e garantuar.

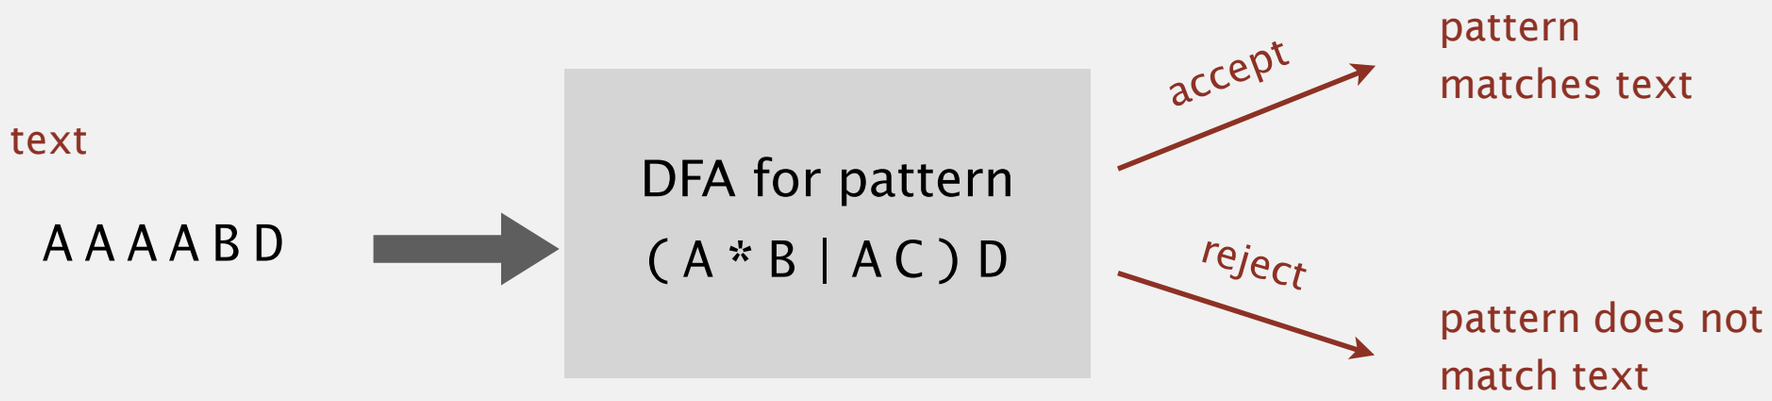


Ken Thompson
Turing Award '83

Abstrakcion. Deterministic finite state automata (DFA).

Plani bazik. [aplikimi i teoremës së Kleene-it]

- Ndërtohet DFA prej RE.
- Simulohet DFA me input prej teksti.

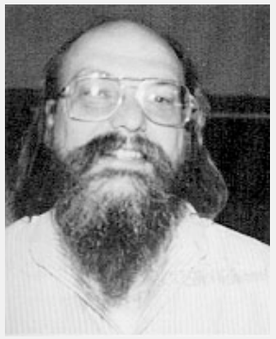


Të metat. Plani bazik nuk është i zbatueshëm (DFA mund të ketë numër eksponencial tw gjendjeve).

Pattern matching implementimi: plani bazik (tentimi i dytë)

Ngjajshëm me KMP.

- Pa backup në input stream për tekst.
- Koha kuadratike e garantuar (zakonisht lineare).

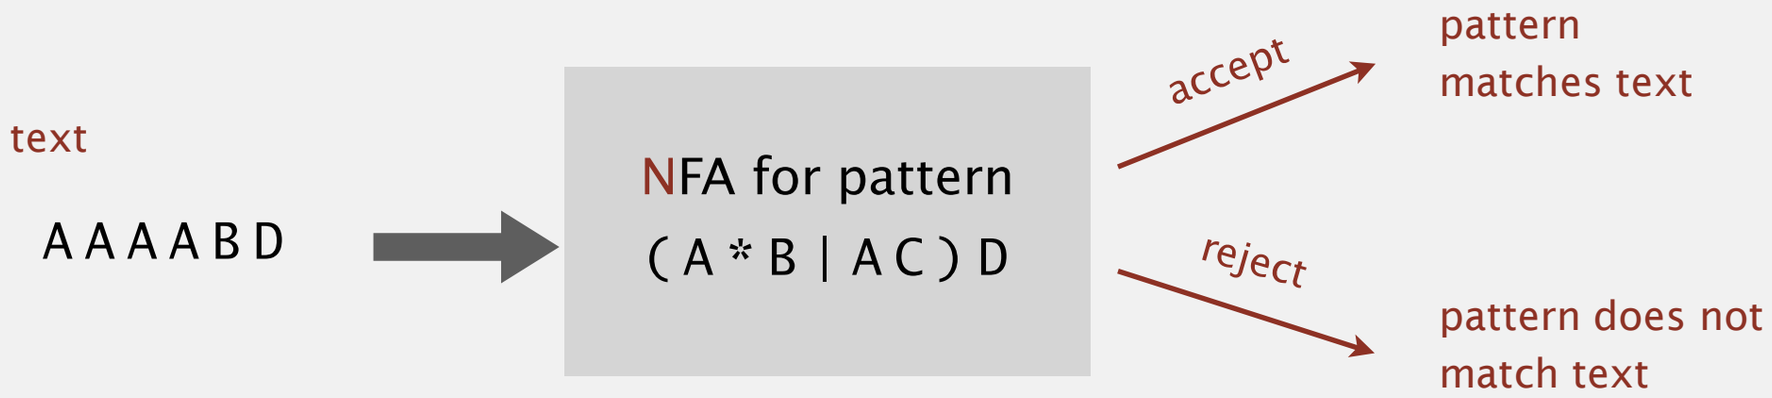


Ken Thompson
Turing Award '83

Abstrakcion. Nondeterministic finite state automata (NFA).

Plani bazik. [aplikimi i teoremës së Kleene-it]

- Ndërtohet NFA prej RE.
- Simulohet NFA me input prej teksti.



Nondeterministic finite-state automata

Regular-expression-matching NFA.

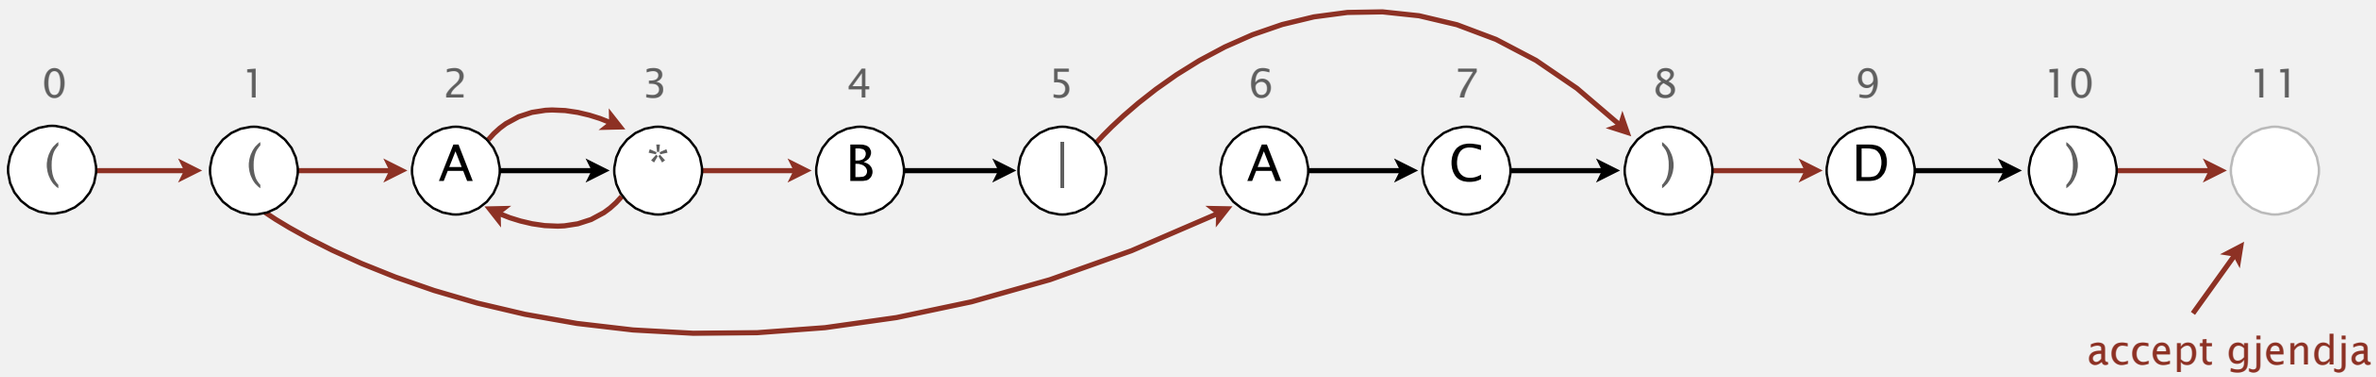
- Supozojmë RE përbrenda kllapave.
- Një gjendje për RE karakter (start = 0, accept = M).
- Kuq εtransicion (ndërron gjendjen,nuk skenon tekstin).
- Zi match transicion (ndërron gjedjen dhe skanon deri në karakterin e ardhshëm).
- Accept nëse cilado sekuencë e transicionit përfundon në accept gjendje.

pas skenimit të të gjithë karaktereve të tekstit

Nondeterminism.

- Këndvështrim: maqina mund të qëllon sekuencën e transicionit të gjendjeve.
- Këndvështrim: sekuenca është një dëshmi që maqina e proceson tekstin

:

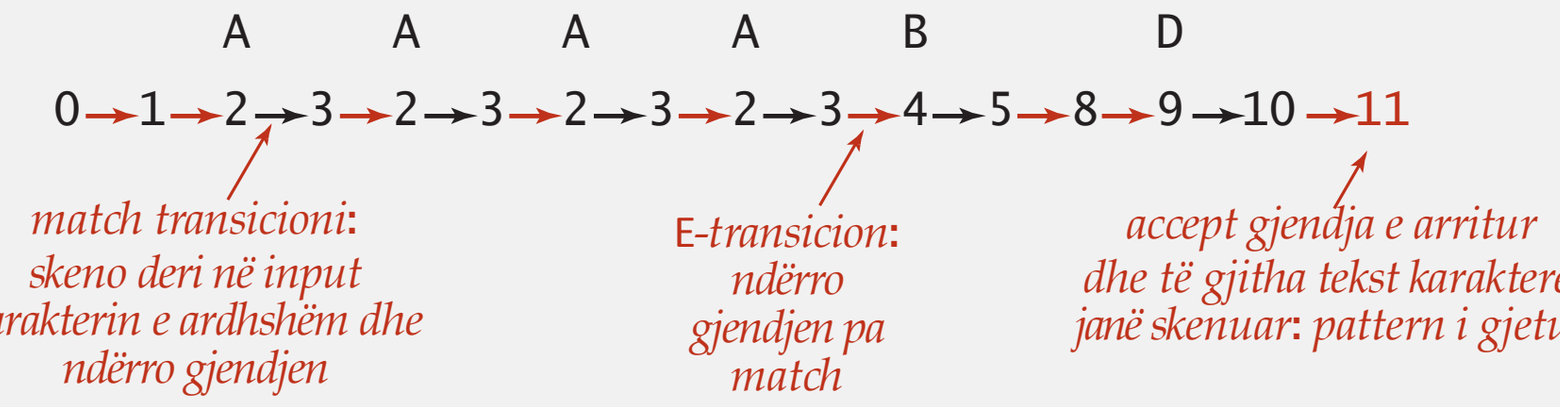


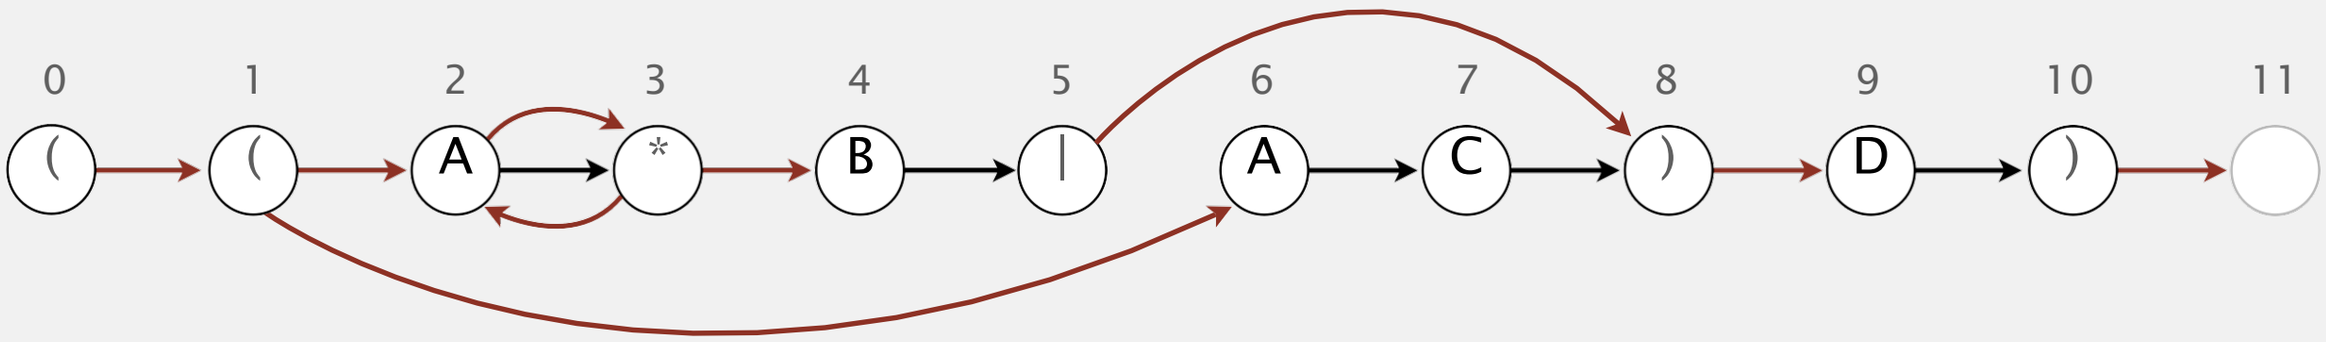
NFA që i përgjigjet pattern-it ((A * B | A C) D)

Nondeterministic finite-state automata

Pyetje: A ka match për A A A A B D nga NFA?

Përgjigje: Po, sepse disa sekuenca të trasicioneve përfundojnë në gjendjen 11.





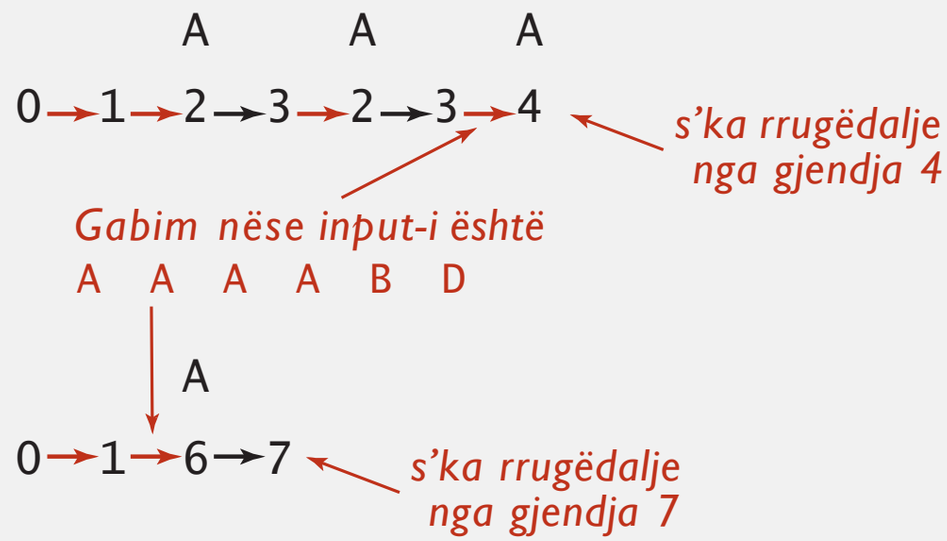
NFA që i përgjigjet pattern-it ((A * B | A C) D)

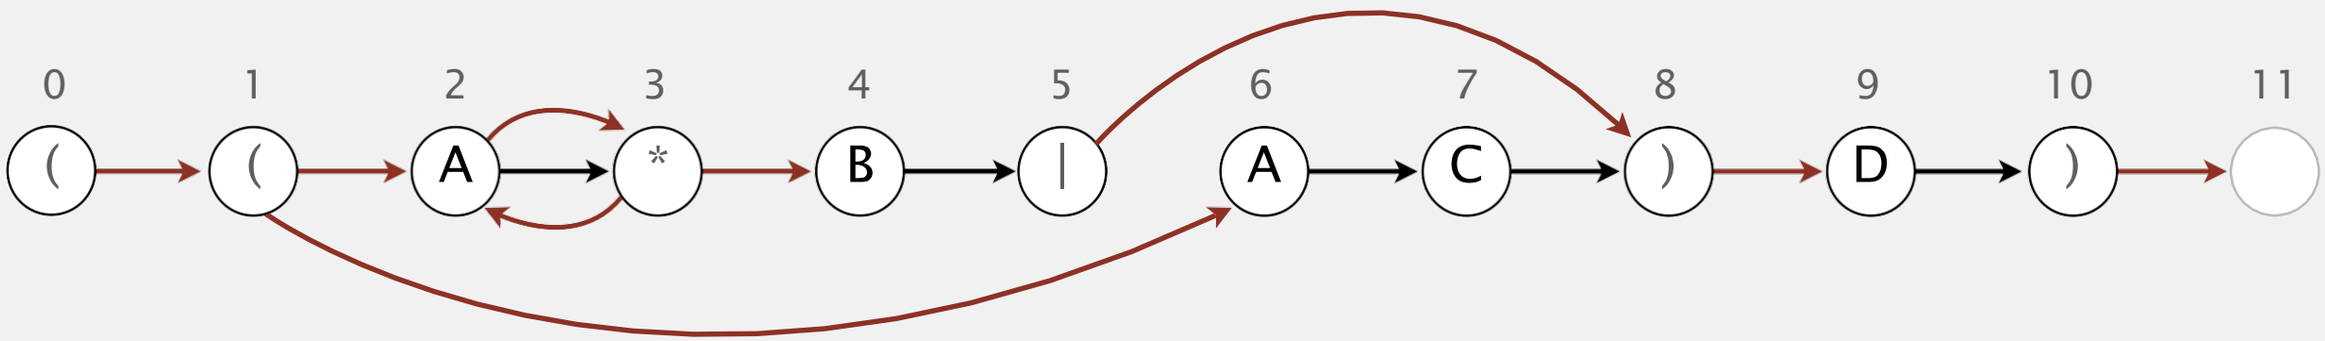
Nondeterministic finite-state automata

Pyetje: A ka match për A A A A B D nga NFA?

Përgjigje: Po, sepse disa sekuenca të trasicioneve përfundojnë në gjendjen 11.

[edhe pse disa sekuenca përfundojnë në gjendje të gabuar ose bllokohen]





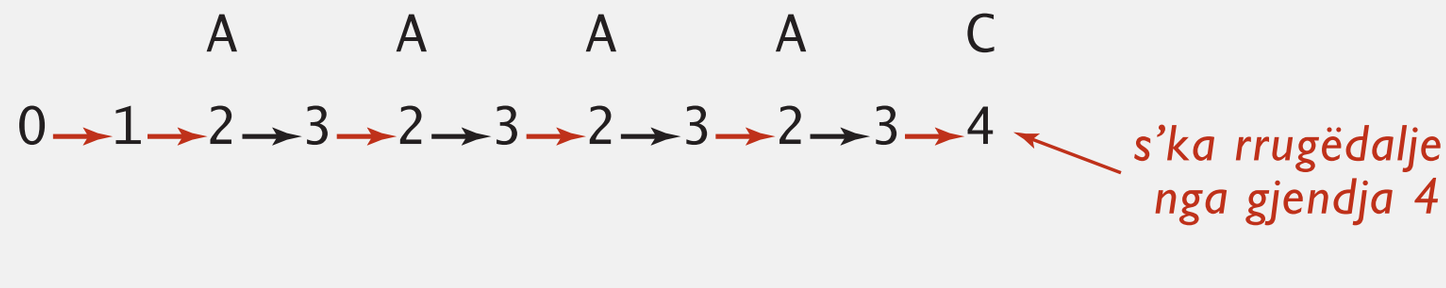
NFA që i përgjigjet pattern-it ((A * B | A C) D)

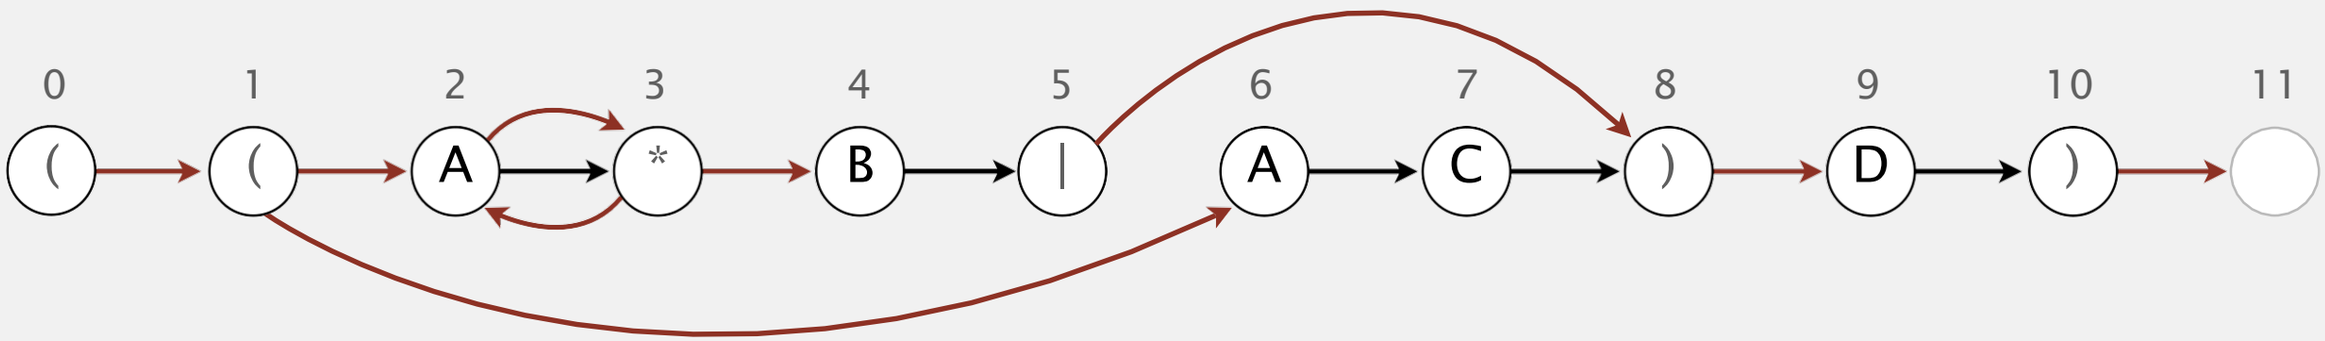
Nondeterministic finite-state automata

Pyetje: A ka match për A A A A B D nga NFA?

Përgjigje: Jo, sepse asnjë sekuencë e trasicioneve nuk përfundon në gjendjen 11.

[but need to argue about all possible sequences]





NFA që i përgjigjet pattern-it ((A * B | A C) D)

Nondeterminismi

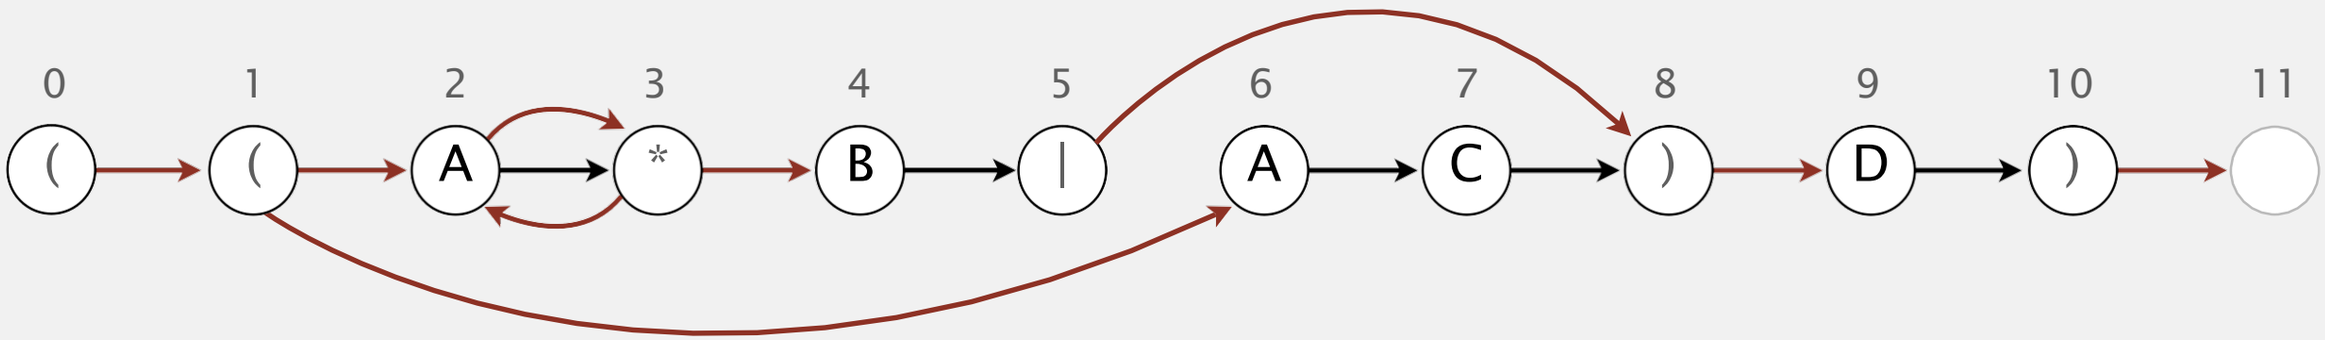
Pyetje. Si të përcaktohet nëse një string është match nga një automaton?

DFA. Deterministic – lehtë, sepse ka vetëm një transicion të aplikueshëm.

NFA. Nondeterministic - Mund të ketë disa transicione të aplikueshme; duhet të përzgjidhet i duhuri!

Si të simulohet NFA?

Sistematikisht të provohen të gjitha sekuencat e transicioneve.



NFA që i përgjigjet pattern-it ((A * B | A C) D)



5.4 Regular Expressions

- *regular expressions*
- *REs and NFAs*
- *NFA simulation*
- *NFA construction*
- *applications*

NFA paraqitja

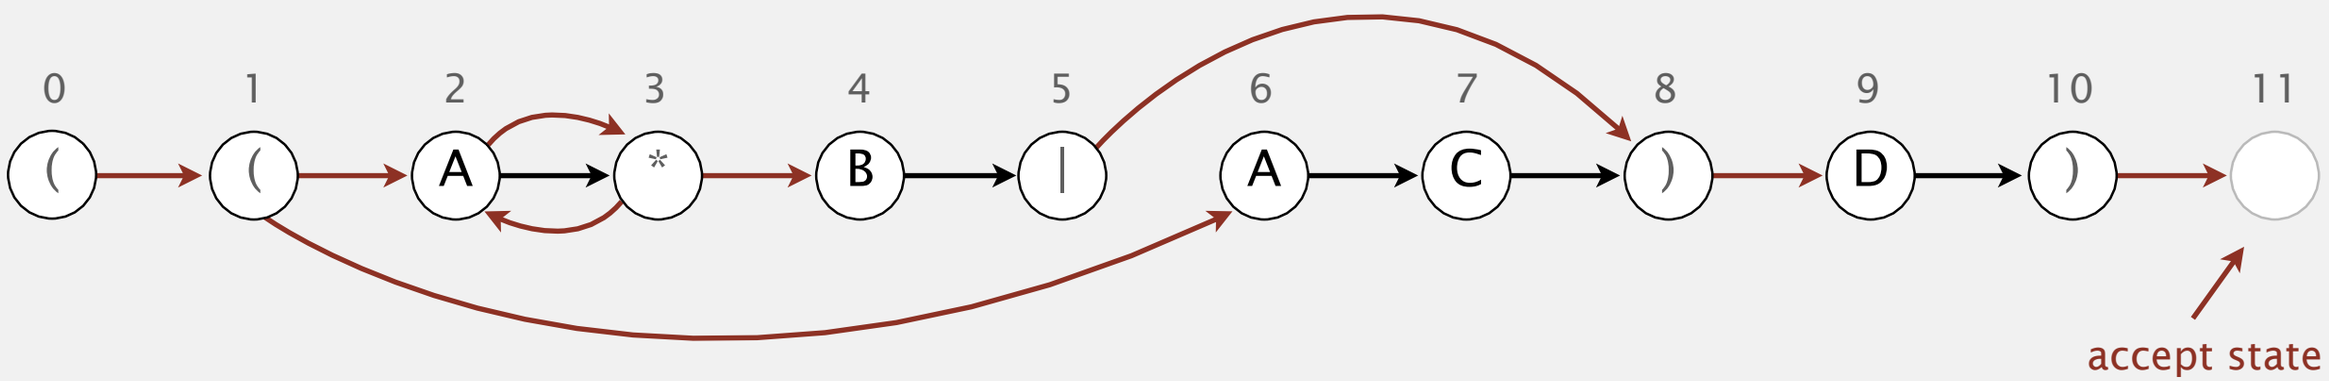
Gjendjet Integer prej 0 deri në M.

numri i simboleve në RE

Match-transicionet. Regular expression mbahen në array `re[]`.

εtransicionet. Ruhen në një digraph G.

0→1, 1→2, 1→6, 2→3, 3→2, 3→4, 5→8, 8→9, 10→11

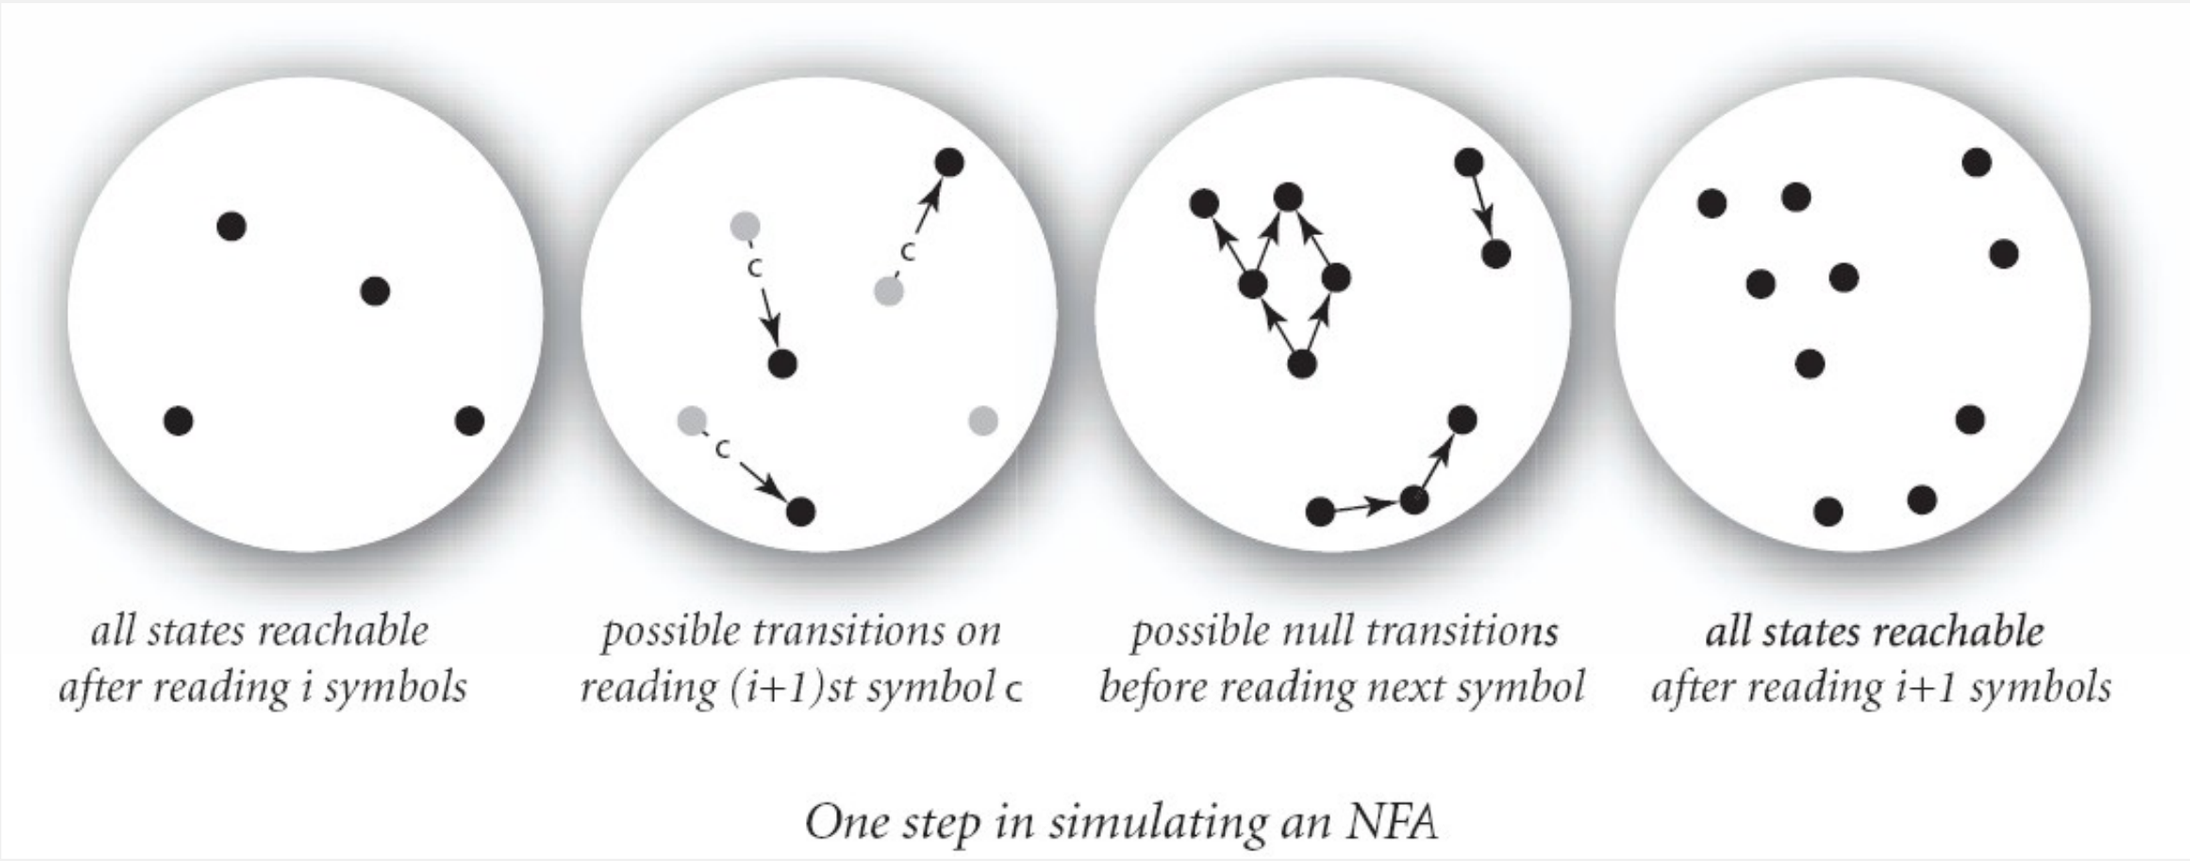


NFA që i përgjigjet pattern-it ((A * B | A C) D)

NFA simulimi

Q. Si simulohet një NFA mënyrë efikase?

A. Të mbahet një bashkësi e të gjitha gjendjeve në të cilën NFA mund të jetë pas leximit të i karaktereve në tekst.



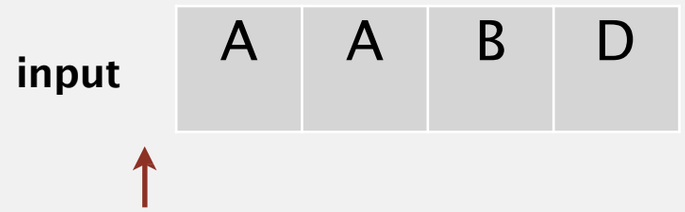
One step in simulating an NFA

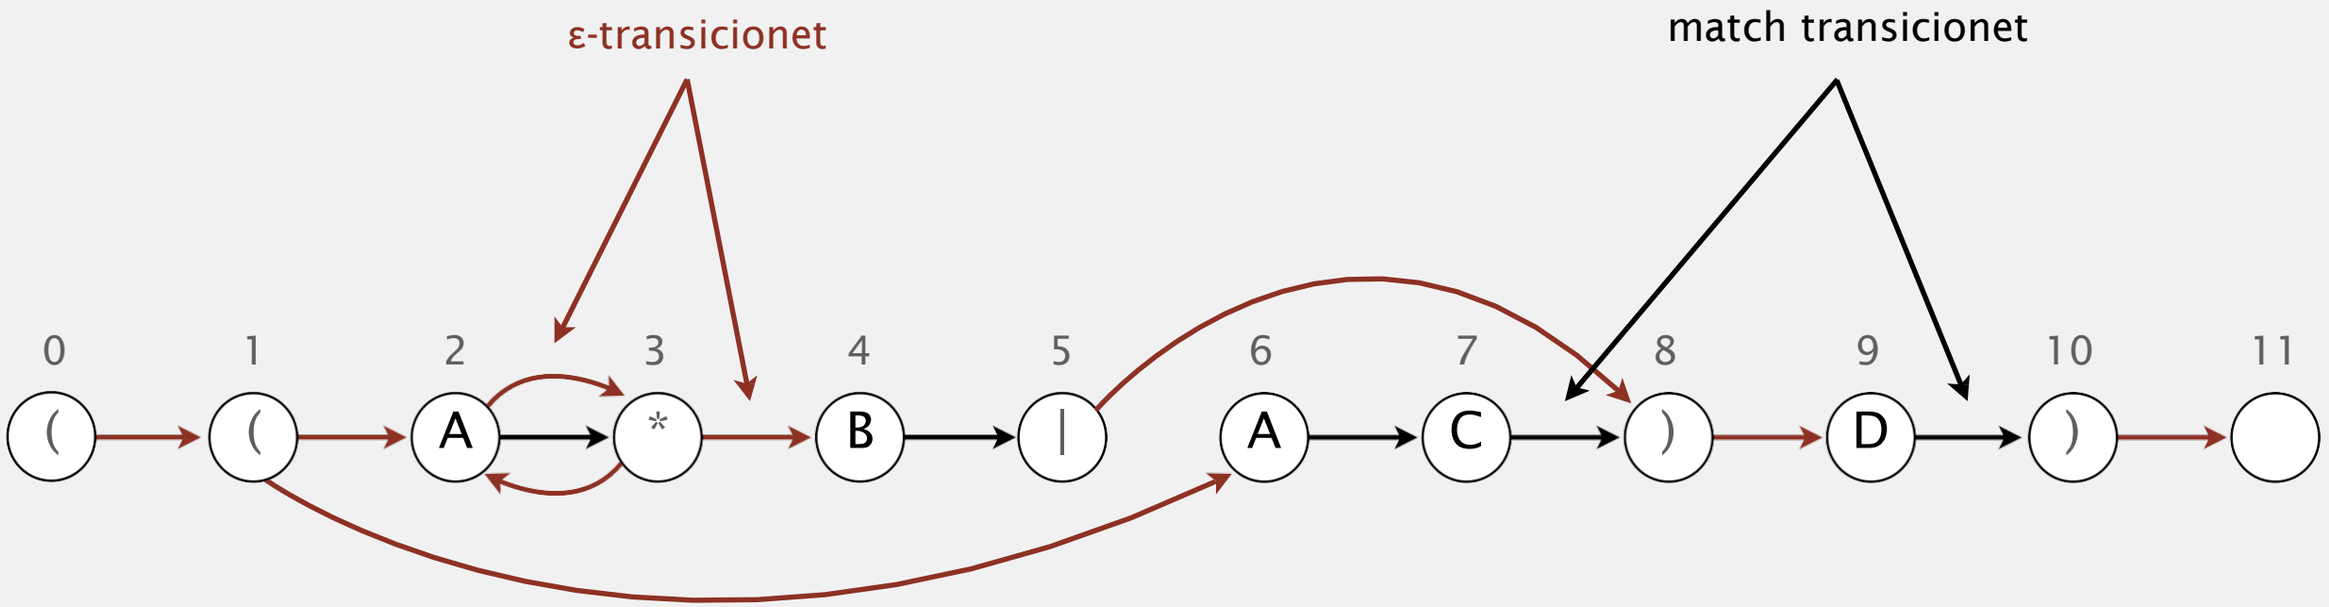
Q. Si mund të arritet reachability?

NFA simulimi demo

Qëllimi. Të provohet nëse input matches pattern.





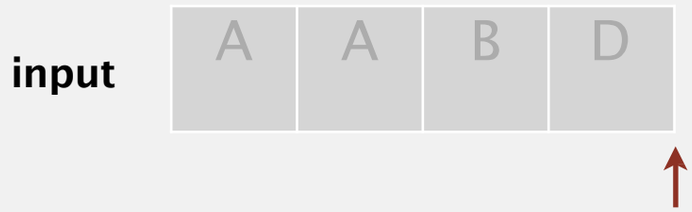


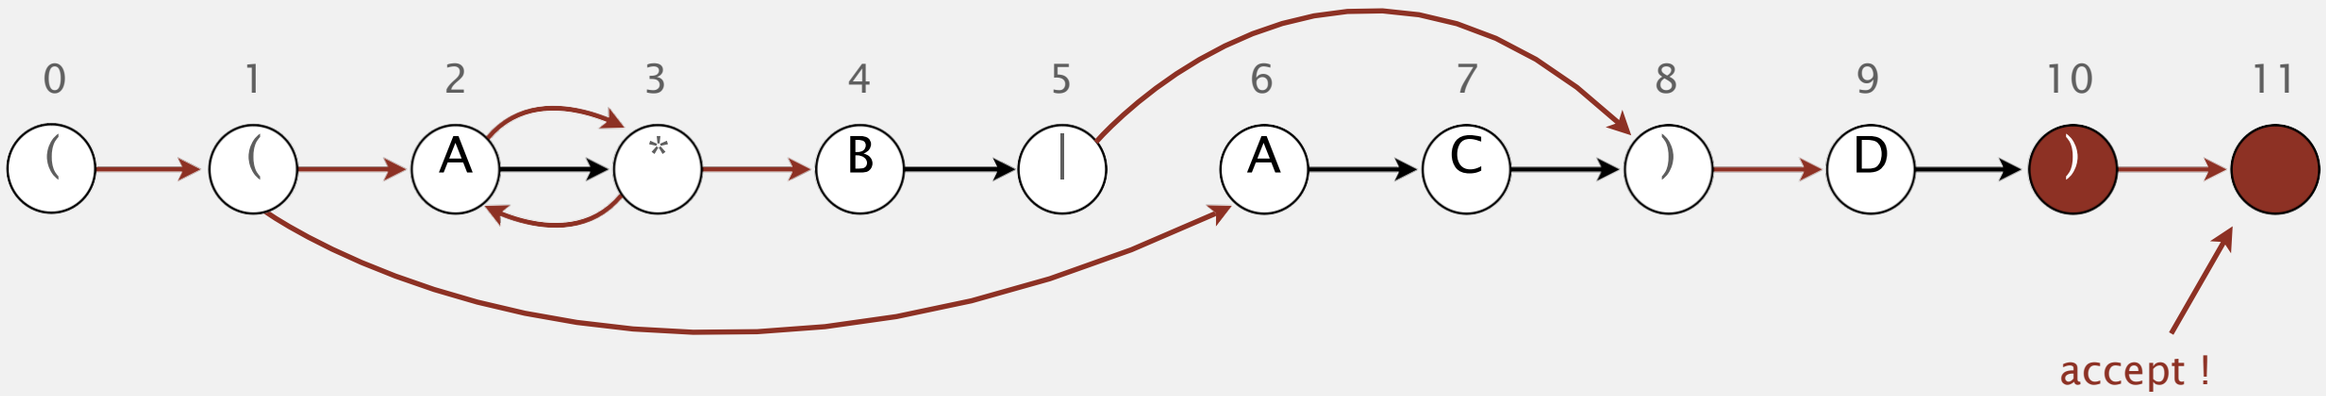
NFA që i përgjigjet pattern-it ((A * B | A C) D)

NFA simulimi demo

Kur të shpenzohen input karakteret:

- Accept nëse cilado reachable gjendje është një accept gjendje.
- Përndryshe reject.





bashkësia e reachable gjendjeve: { 10, 11 }



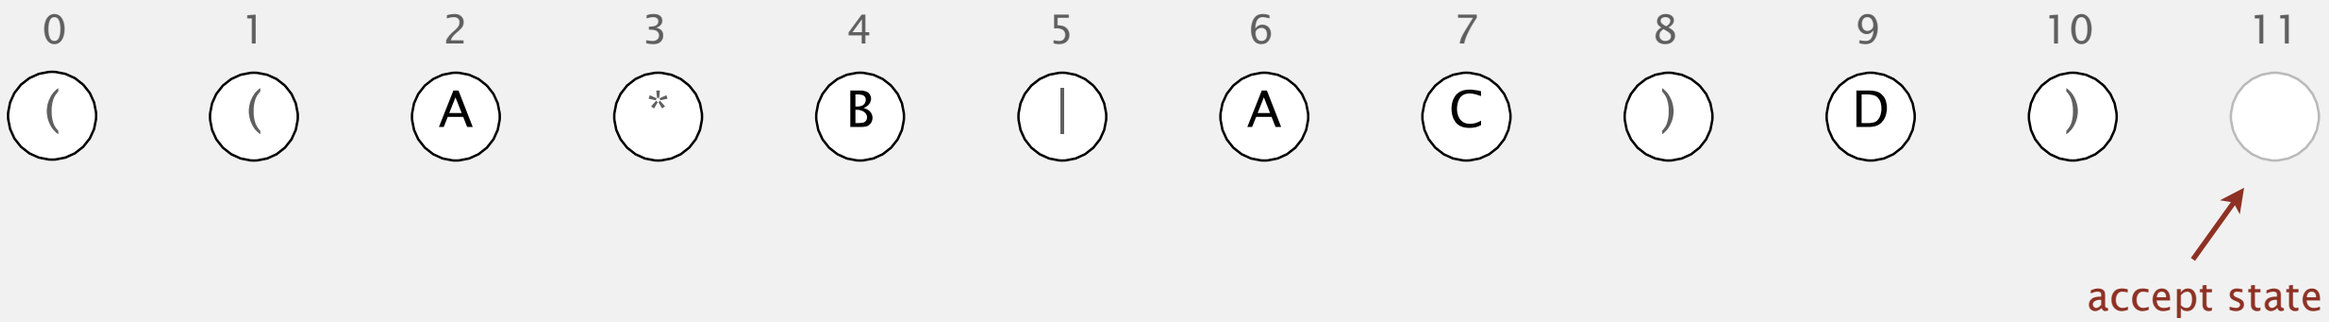
http://algs4.cs.princeton.edu

5.4 Regular Expressions

- *regular expressions*
- *REs and NFAs*
- *NFA simulation*
- *NFA construction*
- *applications*

Ndërtimi i një NFA që korespondon me një RE

Gjendjet. Paraqitet një gjendje për secilin symbol nga RE, plus një gjendje për accept.



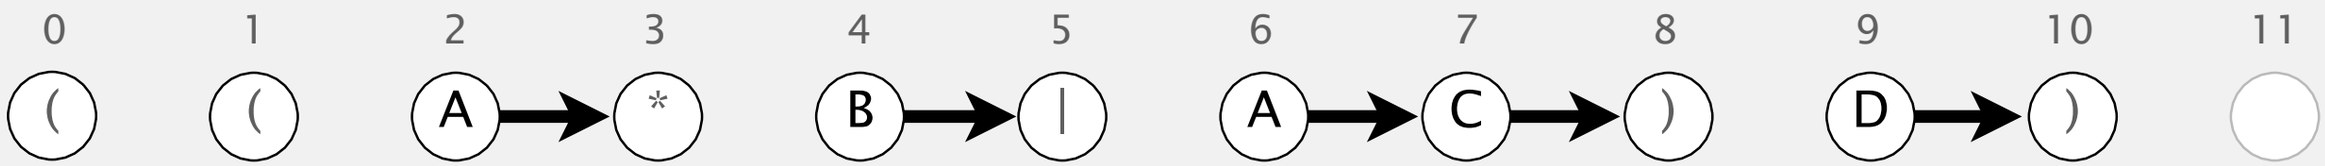
NFA që i përgjigjet pattern-it ((A * B | A C) D)

Ndërtimi i një NFA që korespondon me një RE

Concatenation. Shtohen match-transition segmentet prej gjendjes koresponduese tek karakteret në alphabet, tek gjendja e ardhshme

Alfabeti. `A B C D`

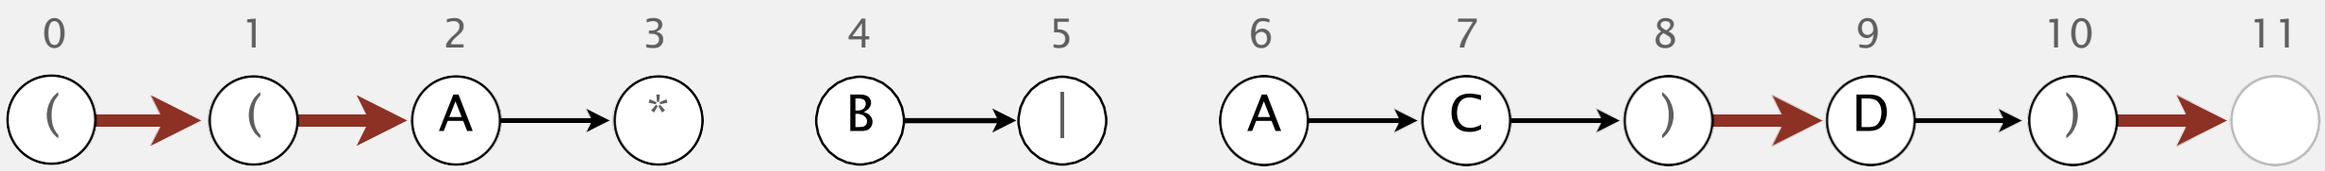
Metakarakteret. `( ) . * |`



NFA që i përgjigjet pattern-it `( ( A * B | A C ) D )`

Ndërtimi i një NFA që korespondon me një RE

Parentheses. Shtohet εtransition segmenti prej parantheses deri tek gjendja e rradhës.

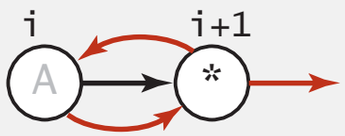


NFA që i përgjigjet pattern-it `( ( A * B | A C ) D )`

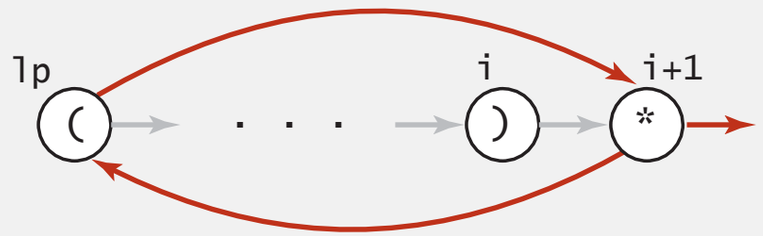
Ndërtimi i një NFA që korespondon me një RE

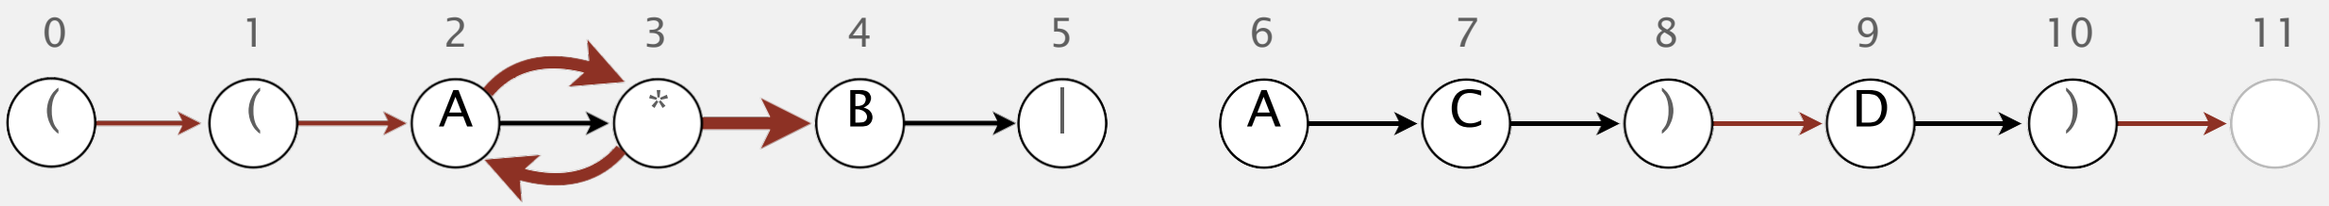
Closure. Shtohen tri ε-transition segmente për çdo * operator.

single-character closure



closure expression

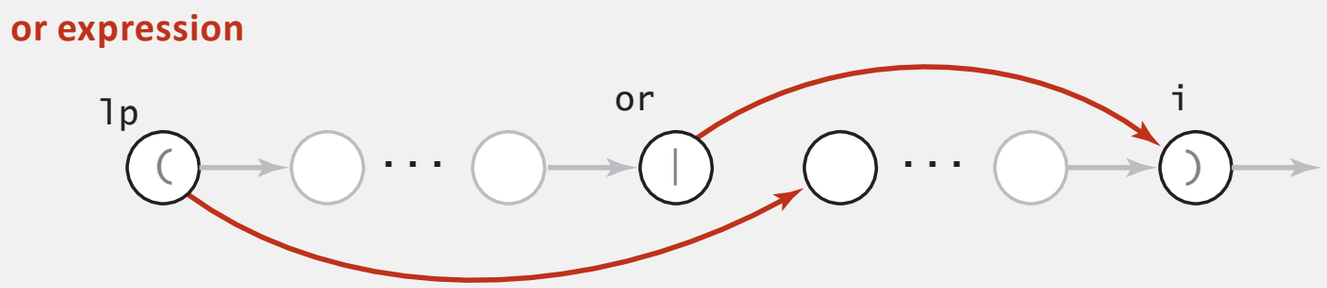


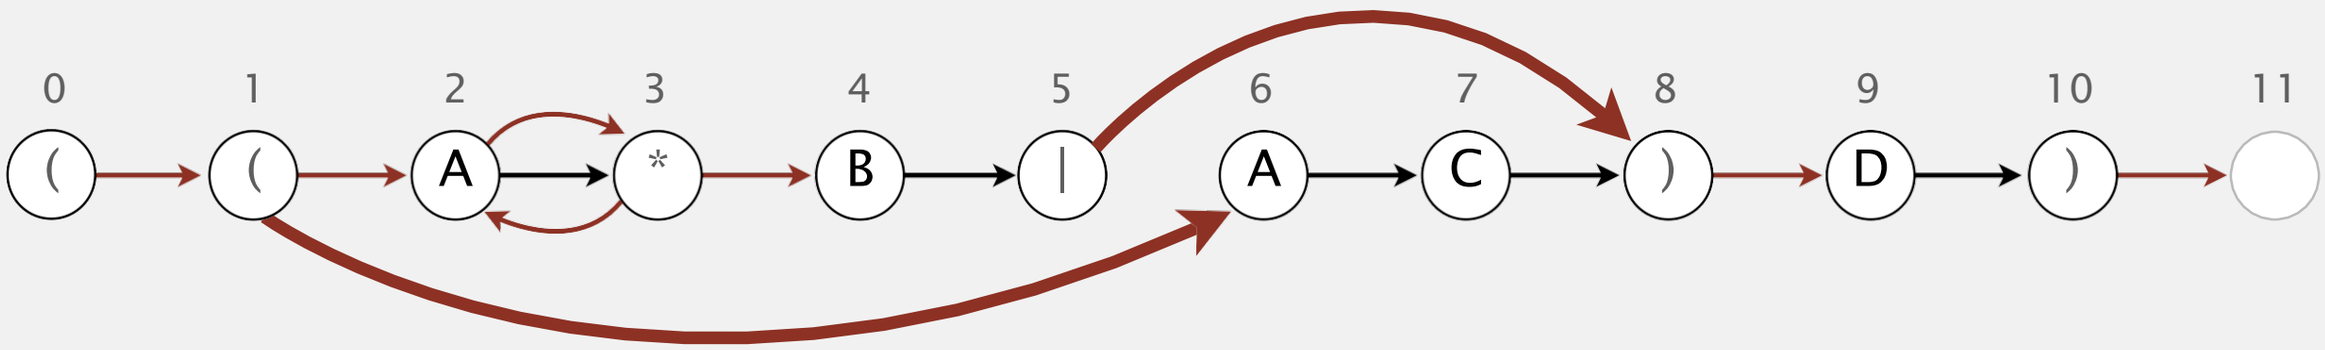


NFA që i përgjigjet pattern-it ((A * B | A C) D)

Ndërtimi i një NFA që korespondon me një RE

Or. Shtohen dy ε-transition segmente për çdo | operator.





NFA që i përgjigjet pattern-it ((A * B | A C) D)

Konstruktimi i NFA : implementimi

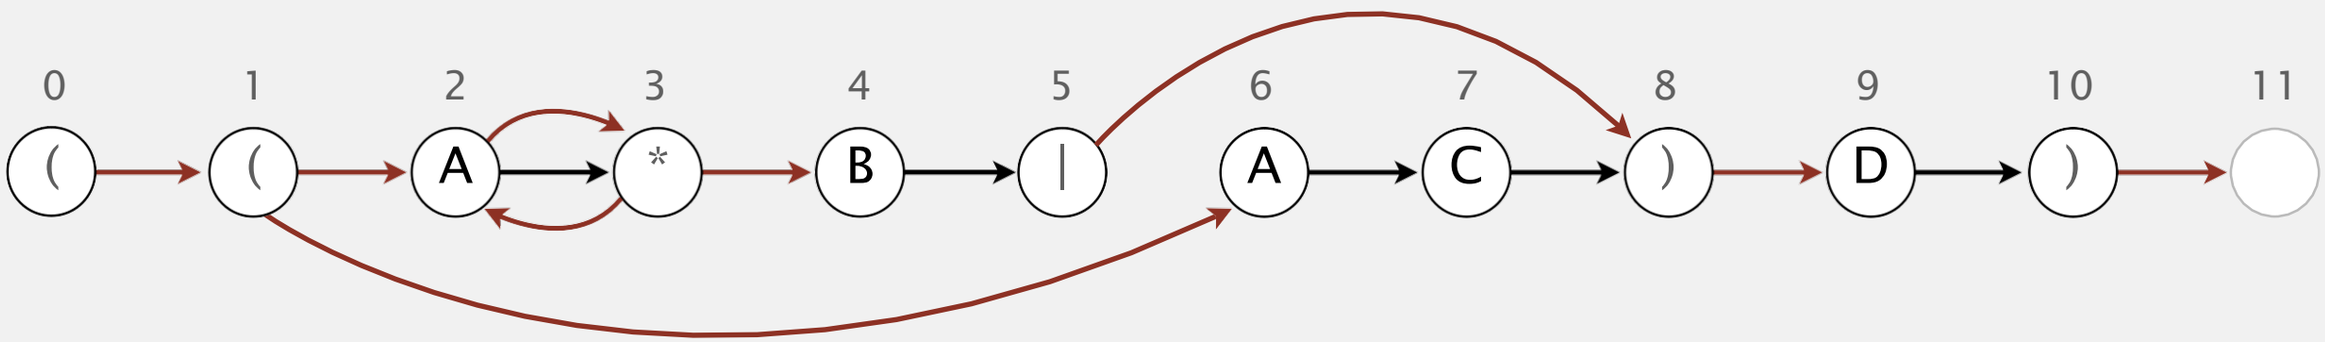
Qëllimi. Shkrimi i një programi që ndërton ε-transition digrafin.

Sfida. Parentheses e majtë ruhet për të implementuar closure dhe or;
| ruhet për të implementuar or.

Zgjidhje. Të mbahet një stack.

- (simboli: push (në stack. push | në
- | simboli: stack.
-) simboli: pop atë që korespondon (dhe çdo | `nëpërmes`;

  shtohen ε-transition segmented për closure/or.



NFA që i përgjigjet pattern-it `( ( A * B | A C ) D )`

Ndërtimi i NFA demo

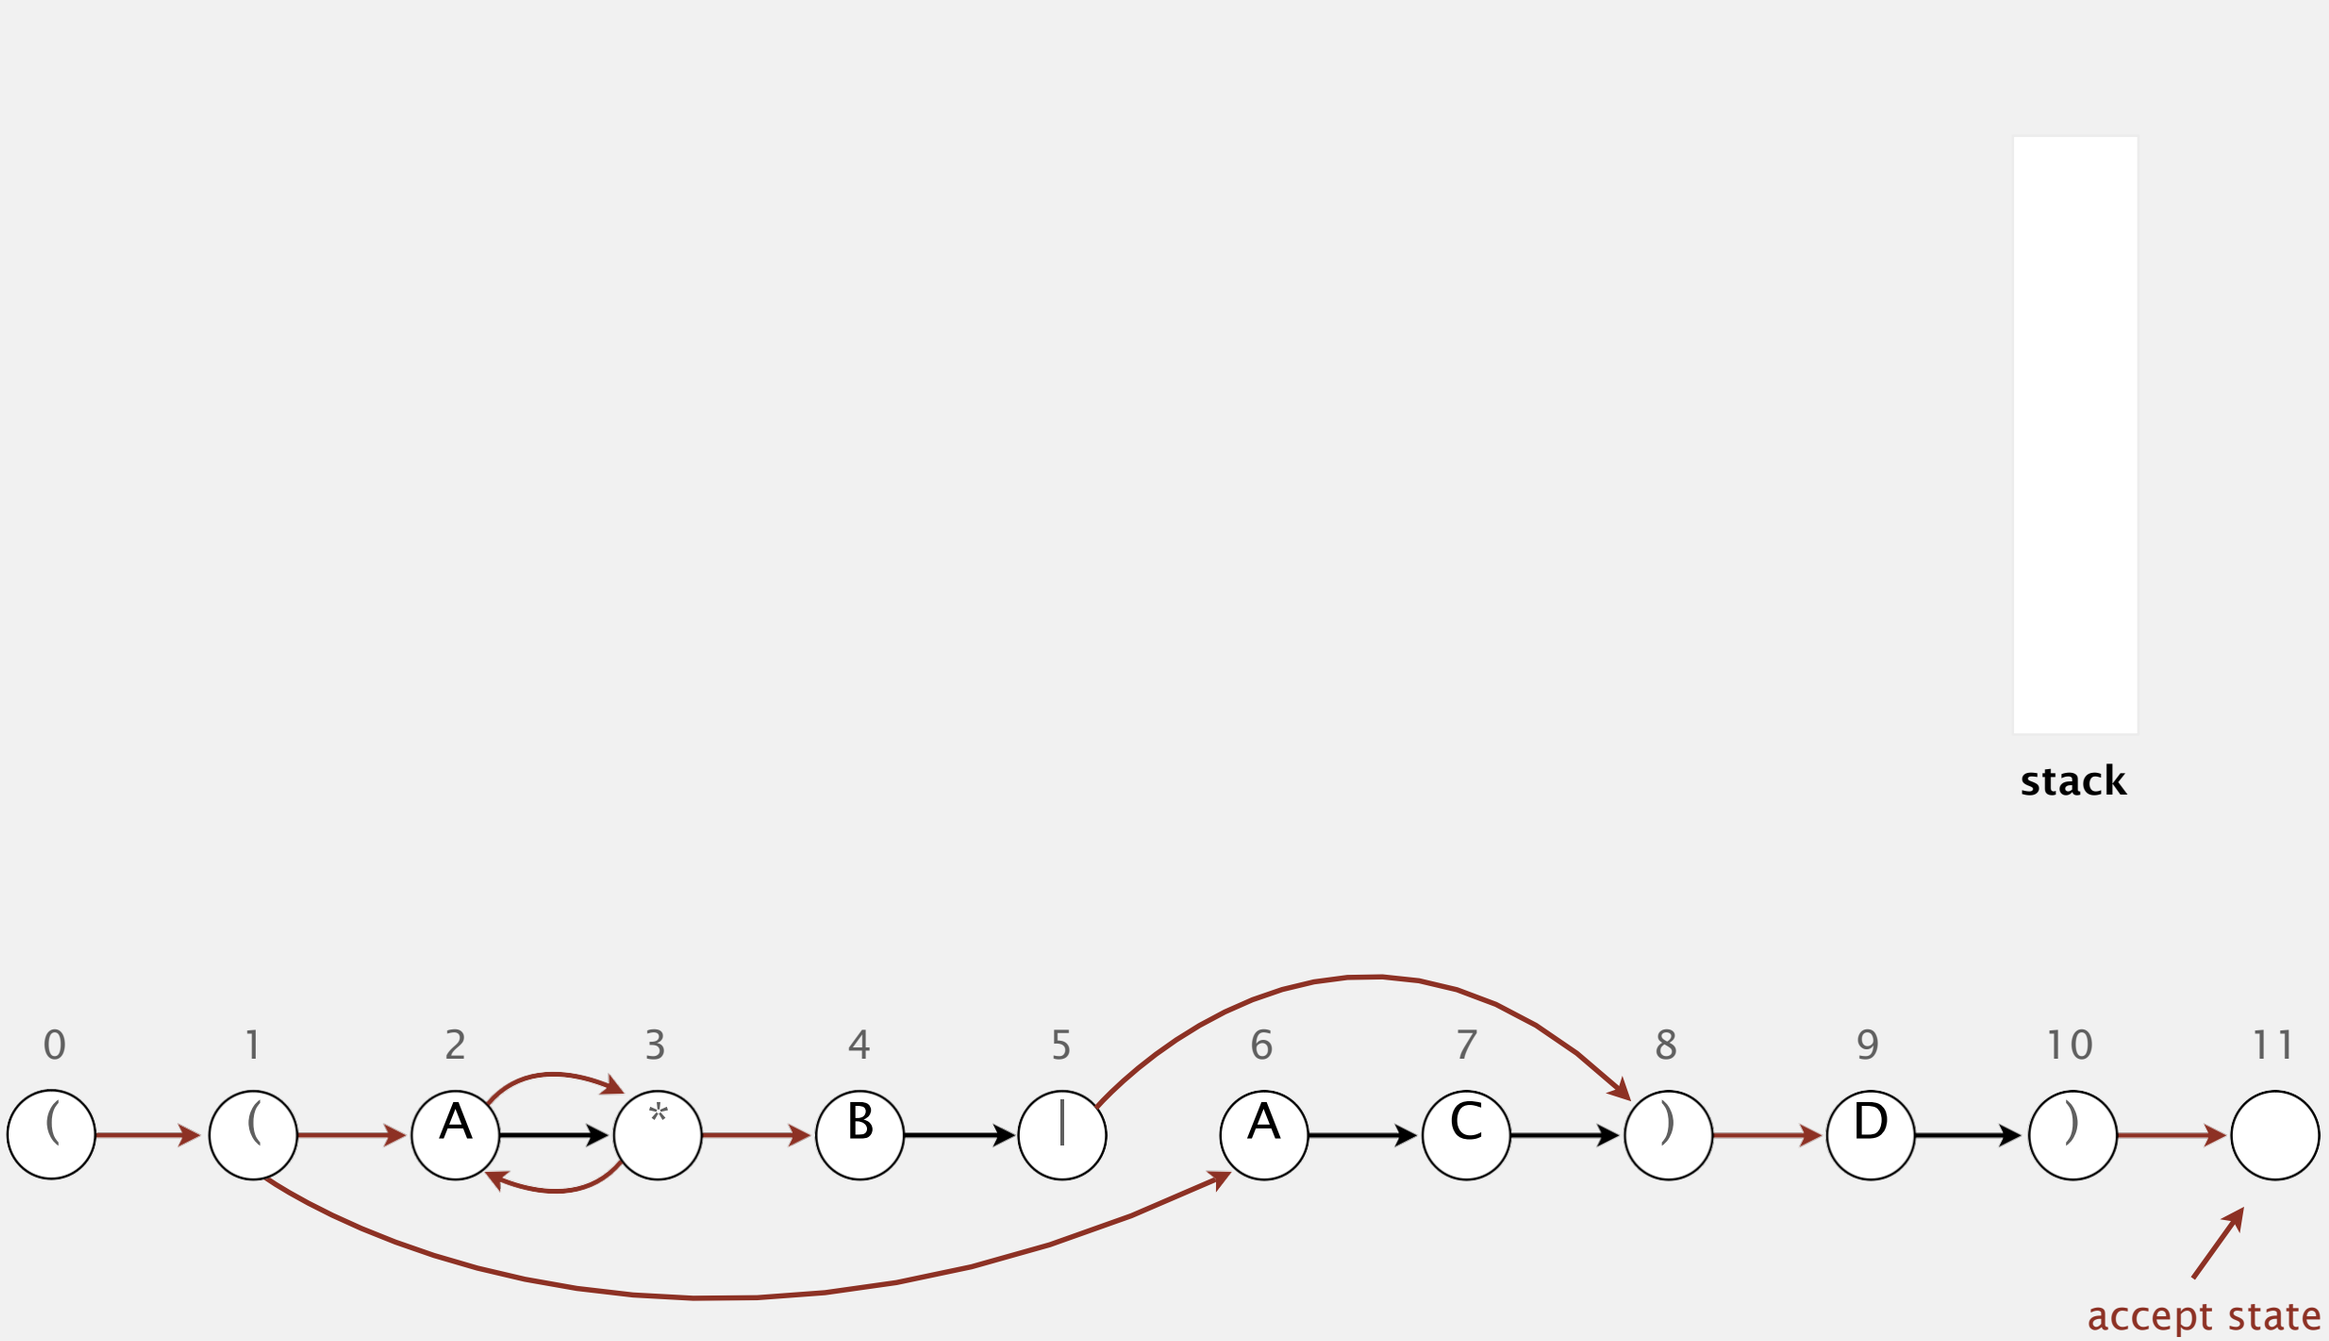


stack

((A * B | A C) D)

Ndërtimi i NFA demo

stack



NFA corresponding to the pattern ((A * B | A C) D)

Konstruktimi i NFA : Java implementimi

```
private Digraph buildEpsilonTransitionDigraph() {
   Digraph G = new Digraph(M+1);
   Stack<Integer> ops = new Stack<Integer>();
   for (int i = 0; i < M; i++) {
      int lp = i;

      if (re[i] == '(' || re[i] == '|') ops.push(i);

      else if (re[i] == ')') {
         int or = ops.pop();
         if (re[or] == '|') {
            lp = ops.pop();
            G.addEdge(lp, or+1);
            G.addEdge(or, i);
         }
         else lp = or;
      }

      if (i < M-1 && re[i+1] == '*') {
         G.addEdge(lp, i+1);
         G.addEdge(i+1, lp);
      }

      if (re[i] == '(' || re[i] == '*' || re[i] == ')')
         G.addEdge(i, i+1);
   }
   return G;
}
```

left parentheses and |

2-way or

closure (needs 1-character lookahead)

metasymbols